

LAPORAN TEKNIS

UJIAN AKHIR SEMESTER — CAPSTONE PROJECT

Mata Kuliah Pembelajaran Mesin — Genap 2025/2026

SMS Spam Detector: Sistem Klasifikasi SMS Spam End-to-End Berbasis Machine Learning dengan Deployment Streamlit

Disusun oleh:

Vasya Citra Narindra

NIM: A11.2024.15987

Kelompok: A11.4501-45XX

*Fakultas Ilmu Komputer — Universitas Dian Nuswantoro
2026*

DAFTAR ISI

SOAL 1: PROBLEM DEFINITION & DATA ACQUISITION

1.1 Latar Belakang & Problem Statement

Layanan pesan singkat (SMS) hingga kini masih digunakan secara luas sebagai kanal komunikasi maupun kanal pemasaran, namun keterbukaan kanal ini turut dimanfaatkan pihak tidak bertanggung jawab untuk mengirim pesan spam maupun pesan phishing yang berpotensi merugikan penerima secara finansial dan data pribadi. Secara manual, pengguna kesulitan menyaring ribuan pesan yang masuk setiap harinya, sehingga dibutuhkan sistem klasifikasi otomatis yang mampu membedakan pesan ham (bukan spam) dan spam dengan akurat.

Proyek ini bertujuan membangun model machine learning yang mampu mengklasifikasikan sebuah pesan SMS sebagai ham atau spam berdasarkan kontennya, kemudian mengemasnya menjadi aplikasi interaktif berbasis Streamlit yang dapat digunakan oleh pengguna non-teknis untuk memeriksa sebuah pesan secara langsung. Karakteristik pesan SMS yang memiliki keterbatasan jumlah karakter mendorong penggunaan bahasa tidak baku (singkatan, slang, typo), sehingga menciptakan noise tinggi yang menjadi tantangan tersendiri dalam pemrosesan teks.

Tujuan bisnis/analisis dari proyek ini adalah: (1) mengidentifikasi pola atau kata kunci yang membedakan pesan spam dan ham; (2) membangun model klasifikasi dengan performa tinggi terutama pada recall kelas spam, agar pesan berbahaya tidak lolos ke ham, tanpa mengorbankan precision secara signifikan; dan (3) menyediakan antarmuka aplikasi yang dapat dipakai untuk demonstrasi prediksi secara real-time.

1.2 Metrik Kesuksesan Proyek

- F1-Score kelas Spam $\geq 0,85$ pada data uji — dipilih karena dataset bersifat imbalanced sehingga akurasi saja tidak representatif.
- ROC-AUC $\geq 0,95$ sebagai indikator kemampuan model memisahkan kedua kelas secara keseluruhan.
- Aplikasi Streamlit dapat memberikan prediksi real-time untuk input teks bebas dari pengguna.

1.3 Sumber Dataset

Nama dataset: SMS Spam Collection Dataset

Sumber: Kaggle / UCI Machine Learning Repository (dataset publik, berbahasa Inggris), diakses melalui mirror publik GitHub

Lisensi: Publik, umum digunakan untuk riset dan pembelajaran text classification

Path lokal pada repository: data/raw/spam.csv

1.4 Statistik Deskriptif Awal

Atribut	Nilai
Jumlah baris (sebelum cleaning)	5.572 pesan

Atribut	Nilai
Jumlah kolom	2 (label, sms)
Tipe data	Kategorikal (label), Teks (sms)
Kelas Ham	4.825 pesan (86,6%)
Kelas Spam	747 pesan (13,4%)
Missing value	Tidak ditemukan
Data duplikat	403 baris (7,2%)

Tabel 1.1 Statistik Deskriptif Awal Dataset

SOAL 2: EXPLORATORY DATA ANALYSIS & PREPROCESSING

2.1 Analisis Kualitas Data

Pemeriksaan kualitas data menemukan tidak ada missing value pada dataset, namun terdapat 403 baris data duplikat (7,2% dari total data) yang kemudian dihapus. Setelah proses cleaning, dataset final berisi 5.169 pesan dengan distribusi kelas Ham 87,4% dan Spam 12,6% — tetap bersifat imbalanced meski proporsinya sedikit berubah dari data mentah.

2.2 Feature Engineering


Sebelum teks dibersihkan, ditambahkan fitur statistik pesan yang secara intuisi berkorelasi dengan karakteristik spam: `char_count` (jumlah karakter), `word_count` (jumlah kata), `has_number` (indikator ada angka), `has_currency` (indikator kata seperti 'free'/simbol mata uang), dan `exclamation_count` (jumlah tanda seru).

2.3 Text Preprocessing

- Case Folding — mengubah seluruh huruf menjadi huruf kecil.
- Cleaning — menghapus angka, tanda baca, dan karakter non-alfabet menggunakan regular expression.
- Tokenizing — memecah kalimat menjadi token/kata berdasarkan spasi.
- Stopword Removal — menghapus kata umum berbahasa Inggris menggunakan daftar stopwords NLTK.
- Stemming — mengubah kata berimbuhan menjadi kata dasar menggunakan PorterStemmer.

2.4 Lima Insight Kunci dari EDA


Insight 1 — Distribusi Kelas



Gambar 2.1 Distribusi Kelas Dataset Setelah Cleaning

Dataset bersifat imbalanced — kelas ham mendominasi ($\pm 87\%$) dibanding spam ($\pm 13\%$), menegaskan pentingnya metrik F1-Score/Recall pada kelas spam.


Insight 2 — Panjang Karakter Pesan



Gambar 2.2 Distribusi Panjang Karakter Pesan per Kelas

Pesan spam cenderung lebih panjang dan terkonsentrasi pada rentang 100-160 karakter (mendekati batas maksimum SMS), sedangkan pesan ham memiliki sebaran panjang yang jauh lebih bervariasi.


Insight 3 — Jumlah Kata per Kelas



Gambar 2.3 Perbandingan Jumlah Kata per Kelas

Median jumlah kata pesan spam lebih tinggi dengan sebaran (IQR) lebih sempit dibanding ham, mengindikasikan pola pesan spam yang lebih seragam/mirip template.


Insight 4 — Korelasi Fitur Numerik



Gambar 2.4 Korelasi Fitur Numerik terhadap Label Spam

char_count dan word_count menunjukkan korelasi positif terkuat terhadap label spam, diikuti has_currency dan has_number — mengonfirmasi fitur statistik sederhana sudah cukup informatif sebagai sinyal awal.

Insight 5 — Kata Paling Sering Muncul



Gambar 2.5 Top 15 Kata pada Pesan Spam

Kata-kata seperti 'call', 'free', 'txt', 'text', 'mobil(e)', 'claim', 'prize' menjadi kata yang paling sering muncul pada pesan spam — konsisten dengan pola umum pesan spam yang menawarkan hadiah atau meminta klaim.

2.5 Data Splitting

Data displit menjadi 70% train (3.618 pesan), 10% validation (517 pesan), dan 20% test (1.034 pesan) menggunakan stratifikasi pada label agar proporsi kelas tetap terjaga pada setiap subset.

SOAL 3: MODELING & EVALUATION

3.1 Ekstraksi Fitur TF-IDF

Representasi teks diubah menjadi vektor numerik menggunakan TfidfVectorizer (maksimum 6.000 fitur), yang di-fit hanya pada data latih untuk menghindari data leakage, kemudian diterapkan pada data validasi dan uji.

3.2 Model & Hyperparameter Tuning

Tiga algoritma diimplementasikan dan dituning menggunakan GridSearchCV (scoring F1, 5-fold cross-validation):


- Multinomial Naive Bayes — tuning parameter alpha (smoothing): {0.1, 0.5, 1.0, 1.5}.
- Support Vector Machine (kernel linear, class_weight='balanced') — tuning parameter C: {0.1, 1, 10}.
- Random Forest (class_weight='balanced') — tuning n_estimators: {200, 400} dan max_depth: {None, 30}.

3.3 Tabel Perbandingan Performa Model (Data Uji)


Model	Best Params	Accuracy	Precision	Recall	F1-Score	ROC-AUC
SVM	C=10	0,9768	0,9280	0,8855	0,9062	0,9904
Random Forest	max_depth=30, n_estimators=400	0,9768	0,9820	0,8321	0,9008	0,9889
Naive Bayes	alpha=0,1	0,9739	0,9333	0,8550	0,8924	0,9855

Tabel 3.1 Perbandingan Performa Model Setelah Hyperparameter Tuning (diurutkan berdasarkan F1-Score)

3.4 Visualisasi Evaluasi



Gambar 3.1 Perbandingan ROC Curve Seluruh Model



Gambar 3.2 Confusion Matrix Naive Bayes, SVM, dan Random Forest (kiri ke kanan)


Ketiga model menunjukkan performa tinggi (akurasi $>97\%$, ROC-AUC $>0,98$). SVM memberikan recall kelas spam tertinggi di antara ketiganya (88,55%) — penting untuk meminimalkan pesan spam yang lolos ke ham (false negative) — dengan precision yang tetap terjaga tinggi (92,80%). Random Forest memiliki precision tertinggi namun recall terendah, sedangkan Naive Bayes berada di posisi menengah pada seluruh metrik.

3.5 Pemilihan Model Terbaik

Berdasarkan F1-Score kelas Spam pada data uji, SVM (kernel linear, $C=10$, $\text{class_weight}=\text{'balanced'}$) terpilih sebagai model terbaik dengan F1-Score 0,9062 dan ROC-AUC 0,9904 — memenuhi kedua metrik kesuksesan proyek yang ditetapkan pada Soal 1 (F1-Score Spam $\geq 0,85$ dan ROC-AUC $\geq 0,95$).

3.6 Interpretasi Model dengan SHAP

SHAP (SHapley Additive exPlanations) digunakan untuk mengidentifikasi kata (fitur TF-IDF) yang paling berkontribusi terhadap keputusan model SVM.



Gambar 3.3 SHAP Feature Importance — Model SVM

Kata	Mean SHAP Value
get	0,0622
im	0,0510
ltgt	0,0454
happi	0,0343
free	0,0339
stop	0,0327
txt	0,0303
ill	0,0291
finish	0,0252
ok	0,0229

Tabel 3.2 Top 10 Kata Berdasarkan Mean |SHAP Value|

Kata seperti 'free', 'stop', 'txt' konsisten mendorong prediksi ke arah spam (nilai fitur tinggi → SHAP value positif), sedangkan kata seperti 'im', 'ill', 'ok', 'happi', 'get' lebih banyak muncul pada konteks percakapan personal (ham). Temuan ini selaras dengan hasil analisis kata pada tahap EDA (Soal 2).


SOAL 4: DEPLOYMENT & STREAMLIT APPLICATION

4.1 Arsitektur Aplikasi

Aplikasi dibangun menggunakan Streamlit dan terdiri atas 5 halaman utama yang dapat diakses melalui menu navigasi pada sidebar. Model terbaik (SVM) beserta TF-IDF vectorizer dimuat dari file .pkl hasil training pada notebook 02_modeling.ipynb, menggunakan fungsi preprocessing yang identik (src/utlis.py) agar konsisten antara tahap training dan inference.

1) Dashboard EDA


Menampilkan statistik dataset (total pesan, jumlah ham/spam, rasio spam), grafik distribusi kelas, distribusi panjang karakter dan jumlah kata, heatmap korelasi fitur, serta kata-kata paling sering muncul — seluruhnya interaktif menggunakan Plotly.



Gambar 4.1 Screenshot Halaman Dashboard EDA

2) Model Demo


Pengguna dapat memasukkan teks SMS bebas (atau memilih contoh), memilih model, lalu mendapatkan hasil prediksi (Ham/Spam) beserta tingkat keyakinan model dan visualisasi probabilitas tiap kelas.



Gambar 4.2 Screenshot Halaman Model Demo dengan Contoh Prediksi Spam

3) Evaluasi Model


Menampilkan tabel perbandingan performa ketiga model, grafik metrik evaluasi, ROC curve, confusion matrix, dan classification report detail per model yang dapat dipilih pengguna.



Gambar 4.3 Screenshot Halaman Evaluasi Model

4) Interpretasi Hasil


Menampilkan visualisasi SHAP feature importance dan ringkasan insight bisnis yang dapat digunakan sebagai dasar pengambilan keputusan non-teknis.



Gambar 4.4 Screenshot Halaman Interpretasi Hasil

5) Dokumentasi

Menjelaskan deskripsi proyek, dataset, metodologi/alur kerja, cara penggunaan aplikasi, struktur repository, dan tim penyusun.



Gambar 4.5 Screenshot Halaman Dokumentasi

4.2 Struktur Kode Aplikasi

- app/app.py — aplikasi Streamlit utama (5 halaman).
- models/best_model.pkl — model SVM terbaik hasil training.

- `models/preprocessing.pkl` — TF-IDF Vectorizer.
- `models/all_models.pkl` — seluruh model terlatih (untuk perbandingan pada Model Demo).
- `src/utils.py` — fungsi preprocessing teks yang dipakai bersama oleh notebook dan aplikasi.
- `requirements.txt` — daftar dependency untuk deployment.

4.3 Rencana Deployment

Aplikasi siap di-deploy ke Streamlit Community Cloud dengan menghubungkan repository GitHub publik. File `requirements.txt` telah disiapkan agar proses build otomatis pada platform deployment berjalan lancar. Link deployment akan dicantumkan pada `README.md` repository setelah proses deploy selesai dilakukan.

SOAL 5: DOCUMENTATION & PRESENTATION

5.1 Struktur Repository

Repository disusun mengikuti template struktur folder standar proyek data science/machine learning:

```
capstone-project/ |— data/{raw,processed}/ |— notebooks/{01_eda.ipynb,
02_modeling.ipynb} |— src/{utils.py, data_preprocessing.py,
train_model.py, evaluate_model.py, eda_plots.py} |—
models/{best_model.pkl, all_models.pkl, preprocessing.pkl} |— app/app.py
|— reports/{figures/, model_comparison.csv, model_results.json} |—
requirements.txt |— README.md |— .gitignore
```

5.2 Dokumentasi README.md

README.md pada repository memuat: ringkasan proyek, tabel perbandingan performa model, struktur repository, instruksi instalasi dan menjalankan aplikasi, tech stack yang digunakan, informasi dataset, serta placeholder untuk link deployment Streamlit dan video presentasi YouTube.

5.3 Presentasi

Presentasi proyek dalam bentuk video akan diunggah ke YouTube, merangkum keseluruhan proyek mulai dari problem statement, proses EDA, hasil modeling, hingga demo aplikasi Streamlit, ditujukan untuk audiens yang tidak harus memiliki latar belakang teknis mendalam.

5.4 Checklist Keluaran Wajib

Keluaran	Status
Problem statement tertulis (≥ 200 kata)	Selesai (Soal 1)
Notebook EDA lengkap dengan visualisasi	Selesai (01_eda.ipynb)
5 insight kunci dari data	Selesai (Soal 2)
Kode training & tuning model	Selesai (02_modeling.ipynb, src/train_model.py)
Tabel perbandingan performa semua model	Selesai (Tabel 3.1)
Visualisasi evaluasi (ROC, CM)	Selesai (Gambar 3.1, 3.2)
Interpretasi model (SHAP)	Selesai (Gambar 3.3)
Aplikasi Streamlit lengkap 5 komponen	Selesai (app/app.py)
Screenshot antarmuka aplikasi	Selesai (Gambar 4.1-4.5)
Laporan Teknis (dokumen ini)	Selesai
Repository GitHub terstruktur	Siap diunggah
Link deployment Streamlit	Menunggu proses deploy
Presentasi YouTube	Menunggu proses rekam & unggah

Tabel 5.1 Checklist Pemenuhan Keluaran Wajib Soal 1-5

KESIMPULAN DAN REKOMENDASI

Kesimpulan

- Dataset SMS Spam Collection bersifat imbalanced (Ham 87,4% vs Spam 12,6% setelah cleaning), sehingga F1-Score dan ROC-AUC menjadi metrik evaluasi yang lebih valid dibandingkan akurasi semata.
- Tiga algoritma (Naive Bayes, SVM, Random Forest) berhasil diimplementasikan dan dituning menggunakan GridSearchCV dengan scoring F1 pada 5-fold cross-validation.
- Model SVM (kernel linear, C=10, class_weight='balanced') terpilih sebagai model terbaik dengan F1-Score kelas Spam 0,9062 dan ROC-AUC 0,9904 pada data uji, memenuhi seluruh metrik kesuksesan proyek yang ditetapkan di awal.
- Interpretasi SHAP menunjukkan kata-kata seperti 'free', 'stop', 'txt' menjadi pendorong kuat prediksi spam, konsisten dengan temuan analisis frekuensi kata pada tahap EDA.
- Aplikasi Streamlit dengan 5 komponen (Dashboard EDA, Model Demo, Evaluasi Model, Interpretasi Hasil, Dokumentasi) berhasil dibangun dan diuji berjalan tanpa galat, siap untuk proses deployment ke Streamlit Community Cloud.

Rekomendasi

- Melakukan deployment aplikasi ke Streamlit Community Cloud dan mencantumkan link-nya pada README.md repository.
- Menambahkan teknik penanganan data imbalanced lanjutan seperti SMOTE untuk dibandingkan efeknya terhadap performa model, khususnya terhadap recall kelas spam.
- Mengeksplorasi metode ekstraksi fitur lain seperti Word2Vec atau model berbasis transformer (BERT) sebagai pembanding terhadap TF-IDF pada penelitian lanjutan.
- Melakukan pengujian pada dataset SMS berbahasa Indonesia untuk mengevaluasi generalisasi metode pada konteks bahasa yang berbeda.
- Menambahkan mekanisme logging/feedback pada aplikasi Streamlit agar prediksi yang salah dapat dikumpulkan untuk keperluan retraining model di masa depan.

DAFTAR PUSTAKA

- SMS Spam Collection Dataset. UCI Machine Learning Repository / Kaggle. Diakses melalui mirror publik GitHub.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). *Advances in Neural Information Processing Systems*.
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273-297.
- McCallum, A., & Nigam, K. (1998). A Comparison of Event Models for Naive Bayes Text Classification. *AAAI-98 Workshop on Learning for Text Categorization*.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- Streamlit Inc. (2024). Streamlit Documentation. <https://docs.streamlit.io/>